

Membandingkan Beberapa Model *Machine Translation* untuk Terjemahan Bahasa Indonesia ke Bahasa Jawa

Andreas Hendra H, Fauziah Hamidah Al Hanief, Rizal Dwi Prasetyo, Kevin Adi Nugroho,
Chrisna Irviano Yohantono

Abstract

Machine Translation (MT) memainkan peran penting dalam mengatasi hambatan bahasa, khususnya antara Bahasa Indonesia dan Bahasa Jawa yang memiliki perbedaan linguistik dan budaya yang signifikan. Meskipun ada kemajuan dalam MT, tantangan tetap ada dalam memastikan akurasi kontekstual, integritas budaya, dan nuansa terjemahan. Penelitian ini bertujuan untuk mengatasi masalah tersebut dengan mengimplementasikan dan mengevaluasi MT menggunakan metode Borda Ranking.

Penelitian ini bertujuan untuk meningkatkan evaluasi sistem MT dengan menerapkan metode Borda Ranking untuk menentukan model terjemahan yang paling efektif dalam penerjemahan Bahasa Indonesia-Bahasa Jawa. Dataset yang digunakan adalah NusaX-MT, yang terdiri dari pasangan teks Bahasa Indonesia-Bahasa Jawa. Metodologi mencakup *preprocessing* data, pemodelan dengan IndoT5, XLMR, NLLB, dan Google Translate, serta evaluasi menggunakan metrik seperti BLEU, METEOR, dan BERTScore. Metode Borda Ranking diterapkan untuk mengintegrasikan metrik evaluasi dan menentukan peringkat kinerja model terjemahan.

Hasil penelitian menunjukkan bahwa model XLMR memberikan kinerja terbaik berdasarkan skor BLEU dan METEOR, yang mengindikasikan kualitas terjemahan yang lebih unggul. Namun, semua model menunjukkan keterbatasan dalam akurasi kontekstual dan nuansa budaya, menyoroti kompleksitas penerjemahan antara Bahasa Indonesia dan Bahasa Jawa. Penerapan metode Borda Ranking menawarkan kerangka evaluasi yang komprehensif untuk sistem MT. Temuan ini menekankan pentingnya pengoptimalan lebih lanjut pada model terjemahan untuk mengatasi tantangan linguistik dan budaya pada pasangan bahasa dengan sumber sedikit seperti Bahasa Indonesia dan Bahasa Jawa.

Keywords: *Machine Translation, Borda Ranking, Indonesian-Javanese, Neural Networks, Low-Resource Languages.*

Introduction

Machine Translation (MT) adalah proses komputasi di mana perangkat lunak atau algoritme digunakan untuk secara otomatis menerjemahkan teks atau ucapan dari satu bahasa ke bahasa lain, menghilangkan kebutuhan akan intervensi manusia. Proses ini biasanya melibatkan analisis bahasa sumber (bahasa dari mana teks diterjemahkan) dan menghasilkan output yang setara dalam bahasa target. Sistem MT menggunakan berbagai pendekatan, termasuk metode berbasis aturan, metode statistik, dan yang terbaru, jaringan saraf untuk melakukan

penerjemahan. Sistem berbasis aturan mengandalkan aturan linguistik dan kamus untuk menerjemahkan teks, sementara *Statistical Machine Translation* (SMT) menggunakan sejumlah besar data teks dwibahasa untuk memprediksi terjemahan yang paling mungkin. Dalam *Neural Machine Translation* (NMT), model pembelajaran mendalam digunakan untuk mempelajari pola-pola kompleks dalam data, secara signifikan meningkatkan kualitas terjemahan. Keuntungan utama dari MT adalah kemampuannya untuk dengan cepat menghasilkan terjemahan dalam berbagai bahasa, menjadikannya alat yang sangat penting untuk mengatasi hambatan bahasa di bidang-bidang seperti bisnis internasional, komunikasi daring, dan layanan pelanggan (D. Puspitaningrum, 2021).

Selain itu, sistem MT dapat terus diperbarui dan ditingkatkan dengan data baru, memungkinkan mereka untuk beradaptasi dengan perubahan penggunaan bahasa dan tetap relevan di lingkungan digital yang berkembang pesat. Namun, meskipun ada kemajuan pesat dalam MT, tantangan tetap ada dalam mencapai terjemahan yang akurat secara kontekstual, idiomatis, dan budaya. Meskipun MT sangat efisien untuk terjemahan dasar, sistem ini masih dapat kesulitan dengan nuansa seperti slang, dialek regional, dan terminologi khusus, yang sering kali menghasilkan terjemahan yang terdengar tidak alami atau semantis yang tidak akurat. Selama beberapa dekade terakhir, MT telah dengan cepat berkembang menjadi alat penting untuk komunikasi lintas bahasa, terutama di dunia globalisasi saat ini, di mana mengatasi hambatan bahasa menjadi semakin krusial. Di berbagai sektor seperti bisnis, pendidikan, pariwisata, diplomasi, dan teknologi, MT memainkan peran penting dalam mendorong komunikasi dan pemahaman lintas budaya. Dengan menerjemahkan konten secara instan, MT memungkinkan komunikasi dan kolaborasi yang lebih cepat antara orang-orang yang berbicara dalam bahasa yang berbeda, mengatasi batasan tradisional yang ditetapkan oleh perbedaan bahasa. Sebagai contoh, perusahaan multinasional menggunakan MT untuk melokalisasi konten mereka dan menargetkan pasar global, sementara platform pendidikan menggunakan MT untuk menawarkan sumber daya dalam berbagai bahasa, memperluas jangkauan mereka ke audiens yang lebih besar (D. Soyusiawaty and B. O. S. Miranda, 2023).

Selain itu, di dunia di mana platform digital dan interaksi online berada di garis depan kehidupan sehari-hari, MT juga telah menjadi sangat penting untuk komunikasi waktu nyata, seperti di media sosial atau layanan pelanggan. Dengan alat seperti Google Translate, pengguna

dapat berkomunikasi lintas bahasa hampir secara instan, mempromosikan konektivitas global dan inklusivitas. Namun, meskipun kemajuannya pesat, penerjemahan mesin masih menghadapi tantangan signifikan. Misalnya, meskipun MT dapat menangani terjemahan dasar, sistem ini sering kali kesulitan dengan makna yang kompleks dan bergantung pada konteks, ekspresi idiomatik, dan nuansa linguistik yang bervariasi antarbahasa. Hal ini menjadikan memastikan akurasi, kesesuaian budaya, dan kelancaran terjemahan sebagai area penelitian dan pengembangan yang terus-menerus dalam bidang MT. Namun, meskipun ada kemajuan dalam teknologi penerjemahan, menerjemahkan antar bahasa dengan perbedaan linguistik dan budaya yang signifikan, seperti Bahasa Indonesia dan Bahasa Jawa, tetap merupakan tugas yang menantang. Secara khusus, kesulitan muncul dalam mempertahankan akurasi, nuansa budaya, dan makna kontekstual saat menerjemahkan antara kedua bahasa ini, yang masing-masing memiliki struktur sintaksis dan kosakata yang berbeda. Dalam penelitian ini, fokusnya adalah menggunakan metode Peringkat Borda untuk mengevaluasi efektivitas sistem penerjemahan mesin dalam menerjemahkan dari Bahasa Indonesia ke Bahasa Jawa (D. A. Sulistyono, A. P. Wibawa, D. D. Prasetya, and F. A. Ahda, 2023).

Masalah utama yang harus diatasi dalam *Machine Translation* (MT) adalah masalah umum terkait dengan akurasi terjemahan. Akurasi terjemahan mengacu pada kemampuan sistem untuk menghasilkan makna yang setara dalam bahasa target yang dengan setia mencerminkan isi dari bahasa sumber. Ini adalah tantangan kritis, karena banyak bahasa memiliki struktur sintaksis, aturan gramatikal, dan kosakata yang berbeda, yang dapat menyebabkan kesalahan terjemahan atau kehilangan makna. Sistem MT tidak hanya harus menerjemahkan kata-kata secara benar, tetapi juga memahami konteks yang lebih luas, struktur kalimat, dan nuansa untuk memastikan bahwa terjemahan tersebut benar secara linguistik dan semantis. Selain akurasi terjemahan secara umum, masalah spesifik lainnya yang memerlukan perhatian adalah menjaga integritas budaya dan kontekstual dalam terjemahan. Setiap bahasa sangat terkait dengan budaya penuturnya, dan makna dari kata-kata, ekspresi, atau idiom tertentu dapat membawa konotasi budaya yang signifikan. Penerjemahan literal dapat menghasilkan output yang canggung atau bahkan menyinggung, terutama ketika berkaitan dengan frasa yang bersifat khusus budaya. Misalnya, ekspresi idiomatik, metafora, atau kehormatan (honorifik) mungkin tidak memiliki padanan langsung dalam bahasa target, dan kegagalan untuk memperhitungkan elemen budaya

ini dapat menyebabkan terjemahan yang terdengar tidak alami atau tidak tepat dalam konteksnya.

Selain itu, integritas kontekstual sangat penting untuk memastikan bahwa terjemahan tidak hanya akurat tetapi juga relevan dengan situasi atau topik tertentu. Dalam banyak kasus, kata atau frasa memiliki makna yang berbeda tergantung pada konteksnya (misalnya, pengaturan formal vs. informal, percakapan profesional vs. percakapan santai). Sistem MT harus dapat mengidentifikasi konteks ini dan menyesuaikan terjemahan dengan tepat untuk menghindari kesalahan atau kesalahpahaman. Masalah ini menjadi semakin menantang dalam bahasa yang memiliki banyak register atau tingkat formalitas, seperti Bahasa Jawa, di mana terjemahan harus mencerminkan bukan hanya kata-katanya, tetapi juga konteks sosial di mana kata-kata tersebut digunakan. Dengan demikian, mengatasi baik akurasi terjemahan maupun integritas budaya dan kontekstual adalah kunci untuk meningkatkan kualitas keseluruhan sistem penerjemahan mesin. Urgensi dari penelitian ini terletak pada meningkatnya permintaan untuk sistem penerjemahan mesin yang dapat diandalkan, terutama di Indonesia, di mana Bahasa Jawa banyak digunakan, dan banyak orang terlibat dalam komunikasi menggunakan Bahasa Indonesia dan Bahasa Jawa. Penelitian sebelumnya tentang penerjemahan mesin dari Bahasa Indonesia ke Bahasa Jawa sebagian besar berfokus pada pendekatan berbasis aturan dan statistik. Namun, metode ini sering kesulitan menangkap kompleksitas fitur linguistik seperti tingkat kesopanan, yang memainkan peran signifikan dalam Bahasa Jawa. Untuk menempatkan penelitian kami dalam domain ini, kami bertujuan untuk memberikan kontribusi dengan menilai penggunaan metode Peringkat Borda sebagai metode evaluasi untuk output penerjemahan mesin, serta mengatasi kekurangan dalam literatur yang ada terkait akurasi terjemahan Bahasa Jawa (D. Puspitaningrum, 2021).

Related Works

Penelitian terkait di bidang penerjemahan mesin (MT) dan studi linguistik sering mengeksplorasi metode serupa dan bertujuan untuk mengatasi masalah yang sebanding, khususnya yang berkaitan dengan akurasi terjemahan dan pelestarian nuansa linguistik serta budaya. Misalnya, studi yang berfokus pada bahasa daerah, seperti penelitian Soyusiawaty dan Miranda (2023) tentang penerjemahan mesin statistik (SMT) untuk Bahasa Indonesia dan bahasa

daerah, telah mengeksplorasi tantangan dalam menyesuaikan sistem MT untuk menangani keberagaman linguistik yang ada di Indonesia. Penelitian mereka bertujuan untuk meningkatkan akurasi terjemahan dengan menangani variasi dialektal dan kosakata daerah tertentu, yang sangat relevan dengan penerjemahan bahasa dengan konteks budaya yang berbeda, seperti Bahasa Indonesia ke Bahasa Jawa. Sebagai contoh, penelitian F. Senovil tentang "Morfofonemik Bahasa Melayu Bengkulu" (2020) mengkaji struktur morfologi dan fonemik bahasa Melayu, memberikan kontribusi untuk pemahaman fitur bahasa lokal, yang penting untuk meningkatkan akurasi MT. Demikian juga, penelitian Ningsih et al. tentang "Derivasi Bahasa Melayu Bengkulu" (2020) mengkaji proses derivasi dalam bahasa daerah yang sama, yang dapat memberikan wawasan dalam pendekatan MT untuk bahasa dengan struktur gramatikal yang kompleks seperti Bahasa Melayu Bengkulu.

Studi-studi ini menunjukkan pentingnya pemahaman karakteristik linguistik bahasa daerah, yang dapat memengaruhi efektivitas sistem MT secara signifikan. Di sisi lain, penelitian seperti makalah Stasimioti et al. (2020) tentang "Kualitas Penerjemahan Mesin" mengevaluasi berbagai pendekatan MT, termasuk Penerjemahan Mesin Statistik (SMT), Penerjemahan Mesin Neural (NMT), dan NMT yang disesuaikan. Analisis komparatif mereka memberikan kerangka untuk menilai kualitas output MT, yang relevan dengan tujuan penelitian ini dalam mengevaluasi kualitas terjemahan dari Bahasa Indonesia ke Bahasa Jawa menggunakan Peringkat Borda. Selain itu, studi-studi tentang bahasa daerah Indonesia secara langsung mengatasi tantangan penerjemahan mesin dari Bahasa Indonesia ke berbagai bahasa daerah. Penelitian Soyusiawaty dan Miranda (2023) tentang penerjemahan mesin statistik dari Bahasa Indonesia ke bahasa daerah secara khusus berfokus pada kompleksitas dan perbaikan dalam menerjemahkan Bahasa Indonesia ke bahasa-bahasa yang digunakan di seluruh Indonesia.

Demikian juga, penelitian tentang penerjemahan Bahasa Sunda, seperti yang dilakukan oleh Fauziyah et al. (2022) tentang "Mesin Penerjemah Bahasa Indonesia-Bahasa Sunda Menggunakan Recurrent Neural Networks," memberikan wawasan lebih lanjut untuk penelitian yang diusulkan dengan menyoroti penggunaan model jaringan saraf canggih dalam penerjemahan mesin. Studi-studi ini relevan dengan penelitian kami karena mereka secara kolektif menekankan pentingnya mengevaluasi metode MT dan meningkatkan akurasi terjemahan, terutama ketika bekerja dengan bahasa yang memiliki karakteristik gramatikal,

morfologis, dan budaya yang khas, mirip dengan tantangan dalam menerjemahkan Bahasa Indonesia ke Bahasa Jawa. Selanjutnya, kemajuan terbaru dalam metodologi penerjemahan mesin neural (NMT) telah memberikan wawasan signifikan dalam meningkatkan akurasi terjemahan. Misalnya, Iida et al. (2019) memperkenalkan mekanisme perhatian multi-langkah untuk penerjemahan mesin neural berbasis RNN, yang meningkatkan kemampuan model untuk menangkap ketergantungan jangka panjang dalam tugas penerjemahan. Liu et al. (2020) mengeksplorasi pre-pelatihan denoising multibahasa untuk NMT, pendekatan yang terbukti efektif dalam meningkatkan kualitas terjemahan untuk bahasa yang kurang sumber daya.

Dong (2022) juga memberikan kontribusi pada bidang ini dengan model jaringan neural berbasis RNN untuk penerjemahan bahasa China-Korea, yang lebih lanjut memvalidasi adaptabilitas dan efektivitas arsitektur RNN dalam berbagai tugas penerjemahan. Sementara itu, Tan et al. (2021) meninjau berbagai metode penerjemahan mesin neural, sumber daya, dan alat, dengan menyoroti kemajuan yang dapat meningkatkan output terjemahan untuk bahasa dengan struktur sintaksis yang unik. Terakhir, Yu et al. (2020) membahas penerjemahan mesin neural untuk bahasa dengan sumber daya rendah, dengan menekankan strategi untuk meningkatkan kualitas MT dalam bahasa dengan data pelatihan terbatas, yang dapat bermanfaat bagi bahasa kurang sumber daya seperti Bahasa Jawa. Studi-studi ini secara kolektif berkontribusi pada pengembangan penelitian yang bertujuan meningkatkan penerjemahan mesin, terutama untuk bahasa dengan karakteristik linguistik dan budaya yang kompleks. Penelitian kami bertujuan untuk membangun dasar-dasar ini dengan memperkenalkan metodologi evaluasi baru, Peringkat Borda, untuk menilai kualitas terjemahan secara efektif, dengan mempertimbangkan baik akurasi linguistik maupun integritas budaya.

Methods

Dalam *machine translation* untuk menampilkan hasil evaluasi Borda Ranking diperlukan beberapa tahap penelitian mulai dari import data dan mengolah data dengan berbagai model yang nantinya akan digabungkan untuk dihitung Borda Ranking nya. Berikut adalah penjelasan material dan metodologi yang digunakan dalam menerapkan evaluasi Borda Ranking pada *machine translation* bahasa Indonesia - Jawa.

1. Material


Data yang digunakan adalah data NusaX-MT yang berasal dari repositori indonlp yang merupakan bagian dari inisiatif pengembangan sumber daya bahasa Indonesia. Kumpulan data ini terdiri dari komentar dan ulasan dari berbagai platform daring yang telah difilter dengan menghapus bahasa kasar dan informasi pengenalan pribadi dengan meninjau semua kalimat secara manual. Dataset ini dirancang untuk mendukung penelitian dan pengembangan sistem *machine translator*, khususnya untuk bahasa daerah di Indonesia, termasuk Bahasa Jawa dan Bahasa Sunda. Secara keseluruhan data yang digunakan adalah 1000, dengan rincian 500 data train, 400 data test, dan 100 data validation.

Tabel 1. Variabel Penelitian

Variabel	Keterangan	Tipe Data
text_1	Teks berbahasa Indonesia	String
text_2	Teks berbahasa daerah (Jawa/Sunda)	String
text_1_lang	Kode bahasa dari teks_1 (ind)	Kategorik
text_2_lang	Kode bahasa dari teks_2 (jav)	Kategorik

2. Methodology

Tahapan analisis dalam penelitian ini adalah dengan studi literatur, import data, preprocessing, visualisasi data, split data train, test, dan validation, kemudian arsitektur model (IndoT5, XLMR, NLBB dan Google Translate), serta evaluasi model menggunakan Borda Ranking. *Flowchart* tahapan penelitian dapat dilihat pada Gambar 1.



Gambar 1. Flowchart Tahapan Penelitian

Adapun penjelasan tahapan penelitian sebagai berikut:

2.1 Studi literatur

Penelitian diawali dengan studi literatur untuk memahami dasar teori terkait *machine translation*, arsitektur model yang akan digunakan, serta metode evaluasi Borda Ranking (Colombo et al., 2024). Tahap ini juga mencakup kajian penelitian-penelitian terkait untuk membangun landasan teoritis yang kuat dan mengidentifikasi jarak antar penelitian yang dapat diisi.

2.2 Import dataset

Dataset diambil dari repositori Hugging Face dengan menggunakan library datasets. Pada tahap ini dilakukan dokumentasi karakteristik dan struktur dataset untuk memahami sifat data

yang akan diolah. Dataset yang digunakan merupakan kumpulan teks *review* berbahasa Indonesia yang diterjemahkan ke dalam bahasa Jawa.

2.3 *Preprocessing data*

Tahapan ini bertujuan untuk membersihkan data agar lebih konsisten dan relevan sebelum digunakan untuk pemodelan *machine translation*. Pada penelitian ini, terdiri dari dua fase utama.

1. Fase pertama adalah *text cleaning*, yang meliputi *case folding* untuk mengkonversi teks menjadi huruf kecil untuk memastikan keseragaman penulisan dan menghindari terjadinya perbedaan makna akibat huruf kapital. Selanjutnya, menghapus tanda baca dan angka agar fokus pemodelan hanya pada kata-kata yang memiliki arti dalam konteks bahasa. Terakhir, proses normalisasi dilakukan untuk mengurangi pengulangan huruf yang ditulis berlebihan, sehingga kata-kata tetap bermakna.
2. Fase kedua adalah *text preprocessing* yang dilakukan adalah tokenisasi yang bertujuan untuk memecah teks menjadi kata per kata. Peneliti juga menggunakan stopwords untuk menghapus kata imbuhan berdasarkan bahasa Indonesia. Terakhir, kata-kata yang telah difilter digabungkan kembali menjadi teks yang bersih, sederhana, dan siap untuk digunakan dalam proses *machine translation*. Preprocessing data sangat penting untuk meningkatkan efisiensi dan akurasi model dengan memastikan data yang digunakan berkualitas tinggi dan bebas dari data yang tidak sesuai dengan tujuan penelitian.

2.4 Eksplorasi dan visualisasi data

Eksplorasi dan visualisasi data dilakukan untuk melihat sebaran data teks yang akan digunakan. Sebelum melakukan visualisasi data, dataset yang terdiri dari data train, data test, dan data validation digabung menjadi satu dengan menggunakan fungsi *concat* dari library *pandas*. Hal ini dilakukan untuk memastikan bahwa visualisasi yang ditampilkan adalah visualisasi keseluruhan data. Peneliti menggunakan visualisasi data *word cloud* dan *barplot* yang menampilkan 10 kata yang paling sering muncul dari dataset..

2.5 *Splitting data*

Splitting data atau pemisahan data digunakan untuk membagi dataset utama menjadi tiga bagian subset data, yaitu data train untuk melatih model, data *testing* untuk evaluasi performa, dan data validasi untuk optimasi model. Proporsi pembagian data divalidasi untuk memastikan keseimbangan distribusi data pada setiap subset

2.6 Tahap modeling

Pada penelitian ini, peneliti menggunakan beberapa model, yaitu IndoT5, XLMR, NLBB, dan Google Translate sebagai *baseline* untuk mengevaluasi performa dalam tugas *machine translation*. Keempat model ini memiliki mekanisme kerja yang berbeda, tetapi semuanya bertujuan untuk meningkatkan kualitas terjemahan bahasa Indonesia, termasuk untuk bahasa daerah seperti bahasa Jawa. Model-model tersebut dilatih dan diuji pada dataset yang sama untuk menghasilkan terjemahan dari teks sumber ke teks target. Hasil terjemahan dari setiap model kemudian disimpan untuk mempermudah proses analisis dan evaluasi lebih lanjut menggunakan metode Borda Ranking.

2.7 Evaluasi dengan Borda Ranking

Setelah melakukan *training* keempat model, hasilnya disimpan untuk menyelaraskan peringkat hasil keempat metode tersebut. Setiap metode dievaluasi berdasarkan beberapa metrik, seperti *Bilingual Evaluation Understudy* (BLEU), *Metric for Evaluation of Translation with Explicit ORdering* (METEOR), dan BERT Score untuk mengukur akurasi terjemahan. Hasil dari setiap metrik digunakan untuk memberikan peringkat pada terjemahan dari masing-masing model. Metode Borda Ranking kemudian menggabungkan peringkat-peringkat tersebut dengan cara memberi bobot tertentu pada hasil dari setiap metrik (Vettoretti et al., 2021). Hal ini menghasilkan skor keseluruhan yang digunakan untuk menentukan model mana yang memiliki performa terbaik berdasarkan kesepakatan dari semua metrik yang digunakan (Chen et al., 2022). Proses ini bertujuan agar evaluasi lebih adil dan seimbang, karena mempertimbangkan kelebihan dan kekurangan dari masing-masing metrik evaluasi.

Result


Sebelum melatih model, langkah awal yang dilakukan adalah prapemrosesan data. Menurut Aggarwal (2018), prapemrosesan data adalah langkah krusial dalam analisis data teks yang bertujuan menghilangkan elemen-elemen yang tidak relevan sehingga pola penting lebih mudah dikenali. Proses ini melibatkan beberapa tahap, yaitu mengonversi semua huruf menjadi huruf kecil, menghapus tanda baca dan angka, melakukan tokenisasi untuk memisahkan teks menjadi kata-kata, menghapus kata-kata yang termasuk dalam *stopword* sesuai dengan bahasa yang digunakan, dan merangkai kembali kata-kata yang telah diproses menjadi satu string. Pada

tahap prapemrosesan data pada variabel *'text_1'* dan *'text_2'* akan disimpan menjadi *'text_1_cleaned'* dan *'text_2_cleaned'*


Setelah tahap prapemrosesan selesai, dilakukan EDA (*Exploratory Data Analysis*) untuk memahami pola utama dalam data teks pada variabel *'text_1_cleaned'* dan *'text_2_cleaned'*. Dua teknik utama yang digunakan dalam analisis ini adalah *Word Cloud* dan 10 Kata yang Paling Sering Muncul (*Top 10 Most Frequent Words*). *Word Cloud* digunakan untuk memvisualisasikan frekuensi kata secara intuitif, di mana kata-kata yang lebih sering muncul dalam dataset ditampilkan dengan ukuran yang lebih besar. Menurut Heimerl et al. (2014), *Word Cloud* efektif dalam memberikan gambaran visual yang cepat tentang tema dominan dalam data teks. Teknik ini membantu mengidentifikasi kata-kata penting atau tema dominan dengan cepat. Selain itu, analisis *Top 10 Most Frequent Words* dilakukan dengan menghitung jumlah kemunculan setiap kata dalam dataset dan menampilkan 10 kata yang paling sering muncul menggunakan grafik batang. Visualisasi ini memberikan gambaran kuantitatif tentang distribusi kata-kata penting dalam data dan membantu mengarahkan eksperimen ke tahap berikutnya. Berikut adalah




Gambar 2. *Word Cloud* Teks Bahasa Indonesia



Gambar 3. *Top 10 Most Frequent Words* Teks Bahasa Indonesia



Gambar 4. *Top 10 Most Frequent Words* Teks Bahasa Jawa



Gambar 5. *Top 10 Most Frequent Words* Teks Bahasa Jawa

Dapat dilihat Hasil dari *Word Cloud* dan *Barplot Top 10 Most Frequent Words* menunjukkan kata-kata yang paling sering muncul dalam dataset yang digunakan. Kata-kata

yang sering muncul pada kedua bahasa cenderung mencerminkan kata-kata dasar dan fungsi yang esensial dalam komunikasi sehari-hari, seperti kata ganti, kata kerja, dan kata depan. Pada *Word Cloud*, kata-kata dalam bahasa Indonesia seperti "saya", "anda", dan "bisa" menunjukkan frekuensi kemunculan yang lebih besar, sementara pada bahasa Jawa dapat dilihat kata-kata seperti “sing”, “ning”, “enak” memiliki frekuensi kemunculan yang lebih besar. Hal ini dapat dilihat juga, pada *Barplot Top 10 Most Frequent Words* yang menunjukkan representasi yang lebih detail dan terstruktur dengan menampilkan 10 kata paling sering digunakan di kedua bahasa.

Selanjutnya, untuk melakukan pelatihan pada model perlu dilakukan *splitting* pada datasetnya. Pada dataset awal yang terdiri dari 1000 data, dengan rincian 500 data untuk *train*, 400 data untuk *test*, dan 100 data untuk *validation*. Namun, rasio distribusi ini kurang optimal untuk melakukan pelatihan model, sehingga dalam penelitian ini dilakukan penggabungan semua dataset awal tersebut dengan menggunakan metode *concat*, lalu membagi ulang dataset dengan rasio 80 : 10 : 10. Berdasarkan rasio tersebut dataset terbagi menjadi 800 data untuk train, 100 data untuk validation, dan 100 data untuk test. Pembagian ini bertujuan untuk memastikan bahwa model machine translation dapat dilatih secara optimal dengan jumlah data pelatihan yang lebih besar, sambil tetap mempertahankan jumlah yang cukup untuk evaluasi dan validasi model.

Lalu, pada tahap *training* dan *testing* digunakan beberapa model *pre trained* dari Hugging Face, yaitu IndoT5 (*LazarusNLP / indo-t5-base-nusax*), NLLB (*facebook / nllb-200-distilled-600M*), dan XLMR (*facebook / mbart-large-50-many-to-many-mmt*), serta satu model non-pretrained, yaitu *GoogleTranslator* dari *library deep_translator*. Setiap model pretrained dilatih selama 10 epoch, dan proses pelatihan dibantu dengan menggunakan API dari *WandB* (*Weights & Biases*), yang menyediakan pelacakan metrik, visualisasi, dan manajemen eksperimen secara real-time. Lalu, untuk proses evaluasi, pada analisis ini menggunakan metrik evaluasi, yaitu Bleu, Meteor, Precision, dan Recall untuk mengukur kualitas terjemahan yang dihasilkan. Setelah mengumpulkan hasil evaluasi dari masing-masing model, semua model tersebut akan disimpan dalam file *pickle* (.pkl) guna untuk melakukan metode Borda ranking dan melihat peringkat kinerja model sebagai salah satu perbandingan dalam analisis ini. Berikut adalah hasil *training* dan *evaluation* dari setiap model dan metode yang digunakan.

1. IndoT5

Tabel 2. Training IndoT5

<i>Epoch</i>	<i>Trainin g Loss</i>	<i>Validation Loss</i>	<i>Accuracy</i>	<i>Bleu</i>	<i>Meteor</i>	<i>Bestcore precision</i>	<i>Bestscore Recall</i>	<i>Bestcore F1</i>	<i>Gen Len</i>
1	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
2	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
3	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
4	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
5	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
6	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
7	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.750000
8	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
9	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000
10	No log	Nan	0.000000	2.343100	0.167300	0.766200	0.766200	0.697200	18.75000

Berdasarkan hasil uji yang telah dilakukan, pada model IndoT5 terlihat bahwa model tersebut melatih data sebanyak 10 kali tanpa kehilangan nilai hasil dari pelatihannya. Pada tabel accuray memperlihatkan nilai 0.000000 pada setiap sesi latihannya yang menunjukkan bahwa model tidak mencapai akurasi. Sementara pada matriks lain untuk evaluasi lain (meteor) menunjukkan nilai yang konstan dari awal hingga akhir yaitu di angka 0.167300. konsistensi tersebut juga terjadi pada bestscore precision, bestscore recall, bestscore F1, Gen len. Hal ini menunjukkan bahwa model tidak menunjukkan perubahan atau peningkatan selama proses pelatihan

Tabel 3. Evaluation IndoT5

<i>Evaluation_result</i>	<i>Nilai</i>
eval_loss	nan
eval_accuracy	0.0
eval_bleu	4.4728
eval_meteor	0.2068
eval_bestcore_precisi on	0.7797
eval_bestcore_recall	0.721
eval_bestscore_f1	0.7484
eval_gen_len	18.56
eval_runtime	15.9851
eval_samples_per_se	6.256

cond	
eval_steps_per_secon	1.564
d	
epoch	10.0

Berdasarkan Hasil uji evaluasi yang telah dilakukan pada model IndoT5, dapat dilihat dalam tabel bagian eva_loss menunjukan hasil nan yang artinya model ini kehilangan evaluasinya, pada eval_accuracy menunjukkan nilai 0.0 yang menunjukkan bahwa model ini tidak berhasil memprediksi dengan benar. Namun pada nilai eval_bestscore_precision, eval_bestscore_recall, dan eval_bestscore f1 menunjukkan nilai yang lumayan bagus yaitu 0.7797, 0.721, dan 0.7484. Yang artinya model ini mampu menangkap dan memprediksi sebagian besar elemen yang relevan.

2. NLBB

Tabel 4. Training. NLBB

<i>Epoch</i>	<i>Trainin g Loss</i>	<i>Validation Loss</i>	<i>Accuracy</i>	<i>Bleu</i>	<i>Meteor</i>	<i>Bestcore precision</i>	<i>Bestscore Recall</i>	<i>Bestcore F1</i>	<i>Gen Len</i>
1	No log	9.447296	0.000000	9.697000	0.321700	0.793900	0.766600	0.779800	25.730000
2	No log	7.657509	0.000000	8.993700	0.340800	0.803600	0.778300	0.790500	24.920000
3	No log	6.703579	0.000000	8.804100	0.349000	0.803600	0.776800	0.788100	28.420000
4	No log	6.167842	0.000000	9.005900	0.356100	0.805300	0.782300	0.793400	27.280000

Berdasarkan hasil uji yang dilakukan, pada model NLBB. Model ini membutuhkan 4 kali iterasi pelatihan selama 4 kali pelatihan tidak ada nilai trainee yang hilang. Nilai accuracy dari model ini adalah 0.000000 pada semua epochnya yang berarti model ini tidak berhasil memprediksi dengan benar pada saat melakukan training. Kemudian pada bestscore precision mendapatkan nilai 0.793900 menjadi 0.805300, bestscore recall sebesar 0.766600 di awal dan menjadi 0.782300, dan bestscore f1 sebesar

0.779500 menunjukkan peningkatan dalam setiap nilainya yang berarti bahwa model ini semakin baik dalam menangkap elemen yang relevan dari data. Hal ini juga dibuktikan dengan nilai validation loss yang semakin menurun setiap sesi training model yang dapat disimpulkan bahwa model menunjukkan adanya peningkatan dalam meminimalkan kesalahan validasi

Tabel 4. Evaluation NLBB

<i>Evaluation_result</i>	<i>Nilai</i>
eval_loss	5.24
eval_accuracy	0.01
eval_bleu	14.8137
eval_meteor	0.3918
eval_bestcore_precisi on	0.8215
eval_bestcore_recall	0.7973
eval_bestscore_f1	0.8089
eval_gen_len	23.66
eval_runtime	14.4304
eval_samples_per_sec ond	6.93
eval_steps_per_secon d	0.901
epoch	10.0

Berdasarkan hasil uji evaluasi terhadap model NLBB, terlihat bahwa nilai dari eval_loss sebesar 5.24 yang menunjukkan bahwa model tersebut berhasil mempertahankan nilai yang cukup baik. Pada eval_bestcore_precision sebesar 0.8215, eval_bestcore_recall sebesar 0.7973, dan eval_bestcore_F1 sebesar 0.8089. Berdasarkan hasil nilai dari ketiga eval tersebut menunjukkan bahwa model NLBB cukup baik dalam memprediksi kata yang benar dan berhasil cukup baik dalam menghindari prediksi salah.

3. XLMR

Tabel 5. Training. XLMR

<i>Epoch</i>	<i>Trainin g Loss</i>	<i>Validation Loss</i>	<i>Accuracy</i>	<i>Bleu</i>	<i>Meteor</i>	<i>Bestcore precision</i>	<i>Bestscore Recall</i>	<i>Bestcore F1</i>	<i>Gen Len</i>
0	No log	8.068418	0.000000	8.560900	0.315500	0.768500	0.741700	0.754300	32.460000
2	No log	5.374328	0.000000	06.41000	0.343200	0.765500	0.750700	0.757200	40.480000
4	No log	3.406597	0.000000	11.924400	0.375800	0.788500	0.766400	0.776900	31.560000
6	No log	2.186911	0.000000	10.815900	0.378600	0.783100	0.766600	0.774300	32.580000
8	No log	1.660526	0.000000	11.194900	0.386000	0.789400	0.772000	0.780100	33.940000
9	No log	1.606776	0.000000	11.262700	0.389000	0.787500	0.771300	0.778800	33.990000

Hasil evaluasi model XLMR berdasarkan beberapa metrik kinerja pada berbagai epoch selama proses pelatihan. Metrik yang diukur meliputi loss pelatihan, loss validasi, accuracy, BLEU, METEOR, serta precision, recall, dan F1 dari nilai Bestscore.

Berdasarkan tabel ini, terlihat bahwa nilai training loss secara konsisten menurun dari epoch 0 hingga 9 yang menunjukkan bahwa model mengalami peningkatan selama pelatihan. Namun, validation loss tidak tercatat ("No log"). Metrik seperti BLEU dan METEOR juga mengalami peningkatan seiring bertambahnya epoch, menunjukkan kemampuan model untuk menghasilkan keluaran yang semakin relevan. Pada epoch terakhir (epoch 9), model mencapai BLEU sebesar 11,26 dan METEOR sebesar 0,389 mencerminkan kinerja optimal dalam menghasilkan prediksi yang mendekati target sebenarnya.

Selain itu, untuk precision, recall, dan F1 score menunjukkan stabilitas dan peningkatan kecil dari epoch awal hingga akhir. Misalnya, precision meningkat dari 0,7685 pada epoch 0 menjadi 0,7875 pada epoch 9. Panjang rata-rata keluaran (Gen Len) juga terlihat stabil di sekitar 33 kata pada epoch terakhir. Hal ini menunjukkan bahwa model mampu menghasilkan keluaran yang konsisten dalam ukuran dan kualitas.

Tabel 6. Evaluation XLMR

<i>Evaluation_result</i>	<i>Nilai</i>
eval_loss	1.539
eval_accuracy	0.0
eval_bleu	13.5445
eval_meteor	0.397
eval_bestcore_precision	0.8109

eval_runtime	25.5684
eval_bestcore_recall	0.7895
eval_bestscore_f1	0.7997
eval_gen_len	26.71
eval_samples_per_second	3.911
eval_steps_per_second	0.274
epoch	9.6

Tabel ini menyajikan hasil evaluasi model setelah proses pelatihan pada epoch tertentu (9.6). Beberapa metrik kinerja utama dicatat, termasuk eval_loss sebesar 1.539, yang menunjukkan tingkat kesalahan model pada data evaluasi. Nilai eval_accuracy tercatat 0, menandakan bahwa model mungkin kurang optimal dalam memprediksi hasil dengan tepat berdasarkan definisi akurasi di sini.

Pada metrik evaluasi lainnya, model mencapai BLEU sebesar 13.5445 dan METEOR sebesar 0.397, yang menunjukkan kemampuan model untuk menghasilkan keluaran yang cukup baik dibandingkan dengan data referensi. Nilai eval_bestscore_precision sebesar 0.8109, recall sebesar 0.7895, dan F1 sebesar 0.7997 menunjukkan keseimbangan yang baik antara prediksi positif dan negatif model.

Rata-rata panjang keluaran model (eval_gen_len) adalah 26.71 kata dengan runtime evaluasi selama 25.5684 detik. Model juga mencatat kecepatan pengolahan sebesar 3.911 sampel per detik (eval_samples_per_second) dan 0.274 langkah per detik (eval_steps_per_second).

4. Google Translate

Tabel 7. Evaluation Google Translate

<i>Evaluation_result</i>	<i>Nilai</i>
eval_bleu	3.1677
eval_meteor	0.2723

eval_bestcore_precision	0.7411
eval_bestcore_recall	0.7195
eval_steps_per_second	0.274

Hasil evaluasi performa Google Translate menggunakan beberapa metrik utama. Nilai eval_bleu sebesar 3.1677 dan eval_meteor sebesar 0.2723 menunjukkan kemampuan terjemahan yang relatif rendah dibandingkan dengan standar referensi, yang menandakan masih terdapat ketidaksesuaian antara hasil terjemahan dan data acuan.

Pada metrik eval_bestcore_precision, Google Translate mencapai nilai 0.7411, menunjukkan tingkat keakuratan prediksi positif yang cukup baik. Namun, nilai eval_bestcore_recall sebesar 0.7195 menandakan bahwa model memiliki sedikit kelemahan dalam menangkap seluruh elemen yang relevan dalam data referensi. Efisiensi evaluasi tercatat dengan kecepatan pemrosesan sebesar 0.274 langkah per detik (eval_steps_per_second), yang cukup stabil untuk proses evaluasi.

5. Borda ranking

Discussion

Berdasarkan hasil penelitian yang dilakukan pada berbagai model, terdapat beberapa temuan penting yang perlu dicatat untuk pengembangan lebih lanjut. Model IndoT5 menunjukkan hasil yang sangat konsisten sepanjang pelatihan, namun tidak menunjukkan peningkatan yang berarti pada akurasi dan metrik lainnya. Hal ini mengindikasikan bahwa meskipun model dapat menangkap sebagian besar elemen relevan dalam data, ia belum mampu mengoptimalkan prediksinya secara keseluruhan.

Sebaliknya, model NLBB menunjukkan peningkatan yang jelas pada metrik precision, recall, dan F1 score selama pelatihan, yang mengindikasikan bahwa model semakin efektif dalam mengenali elemen-elemen yang relevan. Namun, masalah terkait akurasi yang tetap rendah menunjukkan bahwa model masih perlu diperbaiki dalam hal optimasi prediksi. Pada

model XLMR, meskipun terjadi penurunan yang konsisten pada training loss, model ini belum mampu mencapai akurasi yang diharapkan, dengan nilai eval_accuracy yang sangat rendah.

Metrik BLEU dan METEOR yang meningkat memberikan indikasi bahwa model semakin relevan dalam menghasilkan keluaran, meskipun ada ruang untuk peningkatan. Sementara itu, hasil evaluasi Google Translate menunjukkan bahwa meskipun akurasi prediksi relatif baik tetapi kualitas terjemahan yang dihasilkan masih perlu ditingkatkan untuk lebih mendekati standar manusia dengan nilai BLEU dan METEOR yang relatif rendah.

Secara keseluruhan, meskipun beberapa model menunjukkan kemajuan pada metrik tertentu, ada tantangan signifikan terkait akurasi dan kemampuan generalisasi model. Penyesuaian parameter, eksplorasi teknik regularisasi, dan fine-tuning hyperparameter dapat membantu meningkatkan performa model secara keseluruhan.

(Kurang tambahan dari borda ranking)

Conclusion

Berdasarkan hasil uji dari ke empat model yang akan digunakan pada machine translation. Dari keempat model Model IndoT5 adalah model yang memiliki hasil tidak ada peningkatan maupun penurunan selama pengujian, Model deep translation memiliki hasil prediksi yang baik meskipun kualitas terjemahan nya masih perlu ditingkatkan lagi sedangkan pada model NLBB memiliki hasil yang baik dan adanya peningkatan dalam memprediksi elemen yang benar dari data. Dari hasil tersebut kami simpulkan bahwa model NLBB adalah model yang cocok digunakan untuk membangun sebuah machine translation karena Model NLBB memiliki akurasi dalam memprediksi elemen yang benar dengan cukup baik dan ketika dilakukan training terjadi peningkatan dalam menghindari prediksi yang tidak benar.

References

- Aggarwal, C. C. (2018). *Machine Learning for Text*. Springer.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is All You Need. In *Proceedings of NIPS 2017*. (Citation: 6,112)
- A. Shewalkar, D. Nyavanandi, and S. A. Ludwig. (2019). Performance Evaluation of Deep neural networks Applied to Speech Recognition: Rnn, LSTM and GRU. *J. Artif. Intell. Soft Comput. Res.*, 9(4), 235–245.
- B. Premjith, M. A. Kumar, and K. P. Soman. (2019). Neural machine translation system for English to Indian language translation using MTIL parallel corpus. *J. Intell. Syst.*, 18(3), 387–398.
- Baayen, R. H. (2008). *Analyzing Linguistic Data: A Practical Introduction to Statistics*. Cambridge University Press.
- Chen, W., Zhou, R., Tian, Chao., & Shen, Cong. (2022) On Top-k Selection from m-wise Partial Rankings via Borda Counting. arXiv. <https://doi.org/10.48550/arXiv.2204.05742>
- Colombo, P., Himmi, A., Irurozki, E., Noiry, N., & Cl  men  on, S. (2024). Towards more robust NLP system evaluation: Handling missing scores in benchmarks. HAL Archives.
- D. A. Sulistyono, A. P. Wibawa, D. D. Prasetya, and F. A. Ahda. (2023). LSTM-Based Machine Translation for Madurese-Indonesian. *J. Appl. Data Sci.*, 4(3), 190–199.
- D. Datta, P. E. David, D. Mittal, and A. Jain. (2020). Neural Machine Translation using Recurrent Neural Network. *Int. J. Eng. Adv. Technol.*, 9(4), 1395–1400.
- D. Puspitaningrum. (2021). A Study of English-Indonesian Neural Machine Translation with Attention (Seq2Seq, ConvSeq2Seq, RNN, and MHA): A Comparative Study of NMT on English-Indonesian. *ACM Int. Conf. Proceeding Ser.*, 271–280.
- D. Soyusiawaty and B. O. S. Miranda. (2023). Statistical Machine Translation from Indonesian to Regional Languages in Indonesia. *Int. J. Comput. Appl.*, 184(49), 18–23.
- David Chiang. (2007). *Hierarchical Phrase-Based Translation*. Computational Linguistics. (Citation: 1,235)
- Diederik P. Kingma, Jimmy Ba. 2015. Adam: A Method for Stochastic Optimization. In *Proceedings of ICLR 2015*. (Citation: 37,480)

- Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. (2015) . Neural Machine Translation by Jointly Learning to Align and Translate. In Proceedings of ICLR 2015. (Citation: 10,479)
- F. Rahutomo, A. A. Septarina, M. Sarosa, A. Setiawan, and M. M. Huda. (2019). A review on Indonesian machine translation, *J. Phys. Conf. Ser.*, 1402 (7).
- Franz Josef Och. 2003. Minimum Error Rate Training in Statistical Machine Translation. In Proceedings of ACL 2003. (Citation: 3,115)
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Heimerl, F., Lohmann, S., Lange, S., & Ertl, T. (2014). Word cloud explorer: Text analytics based on word clouds. Proceedings of the Annual Meeting of the Association for Computational Linguistics (ACL).
- Ilya Sutskever, Oriol Vinyals, and Quoc V. Le. 2014. Sequence to Sequence Learning with Neural Networks. In Proceedings of NIPS 2014. (Citation: 9,432)
- K. Dedes et al.. (2022). Neural Machine Translation of Spanish-English Food Recipes Using LSTM. *Int. J. Informatics Vis.*, 6(1), 290–297.
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: a Method for Automatic Evaluation of Machine Translation. In Proceedings of ACL 2002. (Citation: 10,700)
- M. S. Alam and A. A. Suryani. (2021). Minang and Indonesian Phrase-Based Statistical Machine Translation. *J. Informatics Telecommun*, 5(1), 216–224.
- M. Stasimioti, V. Sосoni, D. Mouratidis, and K. Kermanidis. (2020). Machine Translation Quality: A comparative evaluation of SMT, NMT and tailored-NMT outputs. *Proc. 22nd Annu. Conf. Eur. Assoc. Mach. Transl. EAMT* , 441–450.
- M. Wahyuni, H. Sujaini, and H. Muhardi. (2019). The Influence of Monolingual Corpus Quantity on Statistical Machine Translation Accuracy. *J. Sist. dan Teknol. Inf.*, 7(1), 20–26.
- N. H. M. Ningsih, D. E. C. Wardhana, and S. Supadi. (2020). Derivasi Bahasa Melayu Bengkulu. *J. Ilm. KORPUS*, 4(2), 224–230, 2020.
- Peter E. Brown, Stephen A. Della Pietra, Vincent J. Della Pietra, and Robert L. Mercer. (1993). The Mathematics of Statistical Machine Translation: Parameter Estimation. Computational Linguistics. (Citation: 5,218)

- Philipp Koehn, Franz J. Och, and Daniel Marcu. (2003). Statistical Phrase-Based Translation. In Proceedings of NAACL 2003. (Citation: 3,713)
- Q. A. Agigi and A. A. Suryani. (2021). Statistical Machine Translation Muna to Indonesia Language. *J. Tek. Inform. dan Sist. Inf.*, 8(4), 2173–2186.
- R. Achmad, Y. Tokoro, J. Haurissa, and A. Wijanarko. (2023). Recurrent Neural Network-Gated Recurrent Unit for Indonesia-Sentani Papua Machine Translation. *J. Inf. Syst. Informatics*, 5(4), 1449–1460.
- Rico Sennrich, Barry Haddow, and Alexandra Birch. (2016). Neural Machine Translation of Rare Words with Subword Units. In Proceedings of ACL 2016. (Citation: 1,679)
- S. E. Sitepu, U. Satya, and T. Bhinneka. (2023). Low-Resource Single-Domain Machine Translation untuk Bahasa Karo-Indonesia Pendahuluan, 1(4), 59–66.
- S. Iida, R. Kimura, H. Cui, P.-H. Hung, T. Utsuro, and M. Nagata. (2019). A Multi-Hop Attention for RNN based Neural Machine Translation. *Proc. 8th Work. Pat. Sci. Lit. Transl.*, 2(18), 24–31.
- Vettoretti, M., & Di Camillo, B. (2021). A Variable Ranking Method for Machine Learning Models with Correlated Features: In-Silico Validation and Application for Diabetes Prediction. *Applied Sciences*, 11(16), 7740. <https://doi.org/10.3390/app11167740>
- Y. Dong. (2022). RNN Neural Network Model for Chinese-Korean Translation Learning,” *Secur. Commun. Networks*, vol. 2(22).
- Y. Liu, J. Gu, N. Goyal, X. Li, and S. Edunov. (2020). Multilingual Denoising Pre-training for Neural Machine Translation, 8, 726–742.
- Z. Tan, S. Wang, Z. Yang, G. Chen, and X. Huang. (2021). Neural machine translation : A review of methods , resources , and tools. *AI Open*, 1, 5–21.
- Z. Yu, Z. Yu, J. Guo, Y. Huang, and Y. Wen. (2020). Efficient Low-Resource Neural Machine Translation with, 19(3), 1–13.